

BMAD Essay Research Guideline Revised for GBR-AD v2

杜博源

2026 年 3 月 12 日

1 实验目标与设置说明

本文面向医学图像异常检测与定位任务，采用 BMAD 统一框架进行训练与评估。当前已完成 RESC 数据集上 RD4AD 的第一组对照实验，并已完成 GBR-AD 的 B0 插件化接入与最小闭环验收。本版 guideline 的修改原则如下。A 组与 B0 组内容保持不变并继续有效。从 B1 开始，实验主线升级为 **GBR-AD v2**，目标是在保留粒计算思想为方法灵魂的前提下，缩小当前版本与顶级会议论文要求之间的差距。

现阶段目标分四层。第一，形成覆盖 BMAD 六数据集的主结果对比，保证结论具备跨域代表性。第二，将粒球机制从“可运行模块”升级为“主表示单元 + 主检测单元 + 主证据单元”，构成 **GBR-AD v2** 的正式方法主线。第三，用困难子集、消融、效率和证据链分析支撑“为什么有效”而不是只给分数。第四，形成可直接进入论文正文和附录的图表、公式、可视化与归档材料。

实验原则如下。训练阶段只使用正常样本。验证与测试阶段同时包含正常与异常样本。所有方法使用一致的输入尺寸、预处理流程与评测脚本。关键结果使用多个随机种子重复运行，并报告均值与标准差。所有 run 需要保存可复现快照与核心产物索引。正式主表只接收统一 stopping policy、统一训练预算、统一评测脚本下得到的结果。

2 实验清单与论文落点

本节给出可直接执行的实验清单。每一项包含实验内容、实施方法、实验目的与论文呈现位置。

2.1 A 必做实验 主结果必须完整

2.1.1 A0 管线验证 (Sanity Check, baseline_debug)

实验内容 在进入任何正式对比 (baseline_full) 之前，先完成一轮最小闭环验证 (baseline_debug)。验证范围覆盖数据读取、训练与测试执行、指标计算、可视化导出、以及可复现快照。当前已完成 RD4AD@RESC 的 baseline_debug，后续每个数据集与每个基线方法均需先过本步骤。

成功判据

- 训练流程正常结束并生成权重文件。
- 测试流程正常结束并导出至少一份核心指标文件，例如图像级 AUROC。
- 导出至少一组异常热力图或定位可视化示例。
- 保存可复现快照，包含运行指令、依赖版本、代码提交记录与关键日志。

实施方法

- debug 训练轮数设为 1 到 5，仅验证闭环可用。
- 固定随机种子与运行环境标识，记录 code commit。
- 产物目录必须包含 checkpoints、metrics、figures、logs。
- 快照文件建议包含 env_python.txt、env_torch.txt、requirements_freeze.txt、git_commit.txt、git_status.txt。

论文呈现 baseline_debug 不进入主结果表。只作为复现实验链路证明，放附录或补充材料一段文字即可。

2.1.2 A1 BMAD 六数据集主表 (baseline_full)

实验内容 在 BMAD 六个数据集上完成完整对比，形成一张主结果表。像素级数据集为 RESC、BraTS、Liver。图像级数据集为 OCT2017、RSNA、Camelyon16。

实施方法

- 每个数据集先完成 A0 的 baseline_debug 验收，再进入 baseline_full。
- baseline_full 阶段锁定全部训练与评估设置，避免中途改动导致不可比。
- 每个数据集统一输入尺寸与预处理流程，全部使用 BMAD 官方 pipeline。
- 每个方法统一训练轮数与评估脚本，保证比较公平。
- 每个设置运行 3 个随机种子，报告 mean 与 std，并保留逐次运行结果与日志。
- 指标口径统一：
 - 图像级数据集：报告 Image-level AUROC。
 - 像素级数据集：报告 Image-level AUROC、Pixel-level AUROC、PRO。

实验目的 建立跨域主结论，并把复现成本压到可控范围。用统一脚本与统一口径，减少审稿人对公平性的质疑。

论文呈现 六数据集主结果表放正文。完整训练细节、额外指标与实现说明放附录。

2.1.3 A2 强基线对齐 (baseline_full, 至少 6 个)

实验内容 在每个数据集上，除 RD4AD 外补齐足够强的 BMAD 内置基线。建议覆盖三类方法，每类不少于 2 个，总数不少于 6 个。所有基线都必须先完成 A0 的 baseline_debug 验收，再纳入 baseline_full。

基线建议

- 特征检索类：包含 PaDiM 与 PatchCore 的同类方法。
- 蒸馏或重建类：在 RD4AD 之外增加至少 1 个同类强基线。
- 一类学习或正则化类：从 BMAD 已集成方法中选择 1 到 2 个代表方法。

实施方法

- 对每个基线，先跑 `baseline_debug`，确认 `checkpoints`、`metrics`、`figures`、`logs` 与快照齐全。
- 对进入主表的 `baseline_full`，锁定输入分辨率、训练轮数、评测脚本与随机种子集合。
- `run` 命名必须包含 `dataset`、`model`、`variant`、`seed`、`host`，便于批量统计与追溯。

实验目的 避免只与弱基线对比，避免只覆盖单一路线。提升主结论可信度，同时降低复现与排错成本。

论文呈现 与 A1 合并为同一张主表，或在主表中加入 `Baselines` 分组说明。完整命令与配置快照放附录。

2.2 B 主实验 引入粒球机制（GBR 主方法）

本节保留 B0 的内容不变，并在其后将原有 B1 以后内容升级为 **GBR-AD v2** 的正式主线。

2.2.1 B0 方法定义与实现边界（GBR-AD，BMAD 插件化）

实验内容 实现一个粒球表示学习异常检测方法，记为 **GBR-AD**。该方法包含四个模块。粒球表示与图构建模块、异常检测模块、定位与分割读出模块、证据与可解释性模块。

方法要点

- **粒球生成（从粗到细）**：对输入做轻度平滑，计算梯度，优先从低梯度位置启动区域生长。通过纯度与方差阈值约束控制最细粒度。
- **粒球节点表征**：每个粒球用其覆盖区域的统计量描述。例如中心、尺度与均值方差等。可用如下统计定义中心与半径：

$$C = \frac{1}{n} \sum_{i=1}^n x_i, \quad r = \frac{1}{n} \sum_{i=1}^n \|x_i - C\|. \quad (1)$$

- **图构建**：以“重叠即连边”为主规则。可选加入邻接边与包含边，形成多关系图。
- **异常打分与反投影**：训练阶段只用正常样本拟合正常图分布。测试阶段输出图像级异常分数，以及节点级分数。节点级分数按覆盖关系反投影回像素域生成 `anomaly map`。重叠区域采用加权融合，得到连续热图。

两种输入路径（必须都做）

- **GRI 路径**：直接在原图上生成粒球图，再做后续学习。
- **GRFM 路径**：先提取预训练 CNN 特征图，再在特征图上生成粒球图并学习。该路径通常收敛更快，泛化更强，作为默认主配置。

成功判据

- GBR-AD 在 RESC 上跑通 `train` 和 `test`，产物齐全。
- 粒球数量统计稳定，能输出每张图的节点数分布与平均重叠度。
- 能导出三类可视化：粒球划分叠加图、证据子图、反投影热图。

论文呈现 方法结构图与伪代码放方法章节。粒球划分与证据热图示例放可视化小节。

2.2.2 B1 版本边界与主线调整（冻结 A 与 B0，升级 B1 以后内容）

版本边界 从本版 guideline 开始，GBR-AD 实验按两个版本管理。

- **GBR-AD v1 provisional:** 指已经完成的 B0 到当前 B1-v1 结果。这些结果用于证明插件化接入、可训练闭环和初步机制信号，不直接进入最终主表。
- **GBR-AD v2 official:** 指本 guideline 新定义的方法与实验主线。从本版之后生成的 run、表格、图像与结论，均以 v2 为准。

冻结规则

- A 组结果与 B0 结果全部保留，不再改写。
- 已完成的 GBR-AD v1 结果保留为 provisional，不删除，不混入最终主表。
- 从新的 B1 开始，所有 proposed 结果统一按 v2 方法、统一 stopping policy、统一训练预算与统一评测脚本重跑。

论文呈现 正文中的正式 proposed 结果一律使用 v2。若需要说明工程演化过程，可在附录增加一段“从 B0 stub 到 B1 v2 的实现演化说明”。

2.2.3 B2 GBR-AD v2 方法定义、完整数理逻辑与架构（正式主方法）

方法总述 GBR-AD v2 的核心思想是：以粒球而非像素或固定网格 token 作为主表示单元，以粒球图而非单一卷积感受野作为主结构单元，以粒球节点异常分数而非后验像素热图作为主检测单元。CNN 或 ViT 特征提取器只提供稳定表征底座，图推理负责在粒球之间传播结构证据，图像级检测、像素级定位与证据链解释均从粒球图读出。

模块划分 GBR-AD v2 按论文口径划分为五个模块。

1. 多尺度粒球生成模块。
2. 异构粒球图构建模块。
3. 粒球图推理与正常性建模模块。
4. 双读出模块，即图像级读出与像素级读出。
5. 证据子图与可解释性模块。

输入路径与统一主链 给定输入图像 $x \in \mathbb{R}^{H \times W \times C}$ ，定义两条输入路径。

- **GRI:**

$$x \rightarrow \mathcal{B}^{raw} \rightarrow G \rightarrow \{a_i\} \rightarrow (S_{img}, A(u), G_E). \quad (2)$$

- **GRFM:**

$$x \xrightarrow{\phi_\theta} \{F^{(1)}, F^{(2)}, F^{(3)}\} \rightarrow \mathcal{B}^{feat} \rightarrow G \rightarrow \{a_i\} \rightarrow (S_{img}, A(u), G_E). \quad (3)$$

其中， $\mathcal{B}^{raw}$ 与 $\mathcal{B}^{feat}$ 分别表示原图粒球集合与特征图粒球集合， G 表示粒球异构图， a_i 表示粒球节点异常分数， S_{img} 表示图像级异常分数， $A(u)$ 表示像素级 anomaly map， G_E 表示证据子图。

B2.1 多尺度粒球生成 对每个尺度 $s \in \{1, \dots, S\}$, 在原图或特征图上生成粒球候选区域 $\Omega_i^{(s)}$ 。先对输入做轻度平滑, 再计算梯度, 并从低梯度区域开始区域生长。记第 s 个尺度上的第 i 个粒球为

$$g_i^{(s)} = (\Omega_i^{(s)}, c_i^{(s)}, r_i^{(s)}, \mu_i^{(s)}, \Sigma_i^{(s)}, b_i^{(s)}), \quad (4)$$

其中 $c_i^{(s)}$ 是中心, $r_i^{(s)}$ 是半径, $\mu_i^{(s)}$ 与 $\Sigma_i^{(s)}$ 分别是区域统计, $b_i^{(s)}$ 表示边界感知统计。中心与半径定义为

$$c_i^{(s)} = \frac{1}{|\Omega_i^{(s)}|} \sum_{u \in \Omega_i^{(s)}} p_u, \quad r_i^{(s)} = \frac{1}{|\Omega_i^{(s)}|} \sum_{u \in \Omega_i^{(s)}} \|p_u - c_i^{(s)}\|_2. \quad (5)$$

为保留“粒计算是灵魂”的方法定位, v2 显式引入粒球质量函数与分裂准则。定义粒球质量为

$$Q(g_i^{(s)}) = \alpha \text{Compact}(g_i^{(s)}) + \beta \text{EdgeAware}(g_i^{(s)}) + \gamma \text{ScalePrior}(g_i^{(s)}), \quad (6)$$

并对每个候选粒球施加如下递归细化规则:

$$\text{split } g_i^{(s)} \quad \text{if } \mathcal{P}(g_i^{(s)}) < \tau_p \text{ or } \text{tr}(\Sigma_i^{(s)}) > \tau_v, \quad (7)$$

其中 τ_p 为纯度阈值, τ_v 为方差阈值。粗粒球负责压缩背景与汇聚全局上下文, 细粒球负责边界、小病灶与低对比局部结构, 形成真正的多粒度粒球金字塔。

B2.2 节点表示与多尺度编码 每个粒球节点的初始表示定义为

$$h_i^{(0)} = [\mu_i, \sigma_i, c_i, r_i, s_i, b_i], \quad (8)$$

其中 μ_i 与 σ_i 为覆盖区域的统计特征, c_i 与 r_i 表示几何中心与半径, s_i 表示尺度编码, b_i 表示边界感知统计。在 **GRI** 中, μ_i 与 σ_i 来自原图区域统计; 在 **GRFM** 中, μ_i 与 σ_i 来自多层 CNN 特征图的区域统计。随后通过节点编码器映射到图推理空间:

$$z_i^{(0)} = \psi(h_i^{(0)}), \quad (9)$$

其中 $\psi(\cdot)$ 为轻量节点编码器, 例如两层 MLP 或线性投影加归一化。

B2.3 异构粒球图构建 定义粒球异构图为

$$G = (V, E, R), \quad (10)$$

其中 $V = \{g_i^{(s)}\}$ 是多尺度粒球节点集合, R 为边关系集合。v2 至少包含四类边:

1. overlap edge: 粒球覆盖区域有重叠即连边。
2. adjacency edge: 粒球边界距离低于阈值 δ 即连边。
3. containment edge: 细粒球与其上层父粒球之间建立包含边。
4. semantic-kNN edge: 在节点表示空间内按 kNN 建立语义近邻边。

四类边对应四类结构作用: 连续区域一致性、边界传播、粗细尺度协同、跨区域语义聚合。

B2.4 关系感知图推理 图推理层定义为 relation-aware 多尺度消息传递:

$$z_i^{(\ell+1)} = z_i^{(\ell)} + \sum_{r \in R} \psi_r \left(\sum_{j \in \mathcal{N}_r(i)} \alpha_{ij}^{(r)} W_r z_j^{(\ell)} \right), \quad (11)$$

其中 R 为边类型集合, $\mathcal{N}_r(i)$ 表示关系 r 下与节点 i 相邻的节点集合, $\alpha_{ij}^{(r)}$ 是关系感知注意力, W_r 是不同关系的线性变换。该层的目标不是单纯做图分类, 而是在粒球之间传播结构证据, 使粗粒球获得全局上下文, 细粒球保留边界与小病灶线索, 并让跨尺度关系显式进入异常检测逻辑。

B2.5 正常性建模与双分数机制 训练阶段仅使用正常样本。设图推理后的节点表示为 z_i ，并定义每个尺度上的正常原型库或正常分布模型为 $\mathcal{M}_{normal}^{(s)}$ 。v2 的节点异常分数不再只依赖单一重建误差，而定义为双分数与结构残差的组合：

$$a_i = \lambda_d d(z_i, \mathcal{M}_{normal}^{(s)}) + \lambda_r \|\hat{h}_i - h_i\|_1 + \lambda_c \Delta_i^{ctx} + \lambda_e \Delta_i^{edge}. \quad (12)$$

其中：

- $d(z_i, \mathcal{M}_{normal}^{(s)})$ 表示节点与正常原型库或正常高斯分布之间的距离。
- $\|\hat{h}_i - h_i\|_1$ 表示解码器重建误差。
- Δ_i^{ctx} 表示图上下文不一致性残差，用于抑制孤立噪声。
- Δ_i^{edge} 表示边关系违约项，用于刻画结构不连续或跨尺度不一致。

该设计的作用是：原型距离更偏向 image-level detection，重建误差更偏向局部异常响应，上下文残差与边关系残差帮助降低误报并增强结构一致性。

B2.6 训练目标 对正常训练样本，定义总损失为

$$\mathcal{L} = \eta_r \mathcal{L}_{rec} + \eta_p \mathcal{L}_{proto} + \eta_c \mathcal{L}_{ctx} + \eta_e \mathcal{L}_{edge}, \quad (13)$$

其中：

$$\mathcal{L}_{rec} = \frac{1}{|V|} \sum_i \|\hat{h}_i - h_i\|_1, \quad (14)$$

$$\mathcal{L}_{proto} = \frac{1}{|V|} \sum_i d(z_i, \mathcal{M}_{normal}^{(s)}), \quad (15)$$

$$\mathcal{L}_{ctx} = \frac{1}{|V|} \sum_i \Delta_i^{ctx}, \quad (16)$$

$$\mathcal{L}_{edge} = \frac{1}{|E|} \sum_{(i,j,r) \in E} \Delta_{ij}^{(r)}. \quad (17)$$

训练阶段的目标是让正常样本在多尺度粒球图上形成稳定、紧凑且结构一致的正常表示，从而使异常样本在测试时表现为节点级偏离。

B2.7 图像级读出 图像级异常分数定义为三部分证据聚合：

$$S_{img} = \beta_1 \text{TopKMean}(a) + \beta_2 \text{SubgraphMass}(G_E) + \beta_3 \text{ScaleConsensus}(a). \quad (18)$$

其中：

- $\text{TopKMean}(a)$ 表示最高异常节点的 top-k 平均分数。
- $\text{SubgraphMass}(G_E)$ 表示证据子图整体异常强度。
- $\text{ScaleConsensus}(a)$ 表示异常证据在多尺度上的一致性。

该读出强调“结构证据链”而非单一高分节点，因此更有利于稳定的图像级检测。

B2.8 像素级反投影与边界感知读出 节点分数按覆盖关系反投影到像素域。对任意像素 u ，其 anomaly score 定义为

$$A(u) = \frac{\sum_{i:u \in \Omega_i} w_{u,i} a_i}{\sum_{i:u \in \Omega_i} w_{u,i}}, \quad (19)$$

其中权重定义为

$$w_{u,i} = w_{u,i}^{dist} \cdot w_{u,i}^{edge} \cdot w_i^{purity} \cdot w_i^{scale}. \quad (20)$$

各项含义如下：

- w^{dist} ：像素到粒球中心越近，权重越大。
- w^{edge} ：边界区域更信任细粒球与边界感知节点。
- w^{purity} ：纯度高、方差受控的粒球更可信。
- w^{scale} ：小半径粒球在像素级定位中权重更大，避免大粒球稀释小病灶与边界。

为进一步提升边界恢复质量，可在最终热图后接一个轻量细化头，但该细化头只允许作为粒球反投影的局部边界校正器，不能替代粒球主表示与主读出链条。

B2.9 证据子图与可解释性输出 定义高异常节点集合为

$$V_E = \{i \mid a_i > \tau_a\}, \quad (21)$$

对应证据子图为

$$G_E = G[V_E]. \quad (22)$$

最终系统输出四类结果：

- 图像级分数 S_{img} 。
- 像素级 anomaly map $A(u)$ 。
- 证据子图 G_E 。
- 粒球划分叠加图、证据热图与失败模式可视化。

该模块保证方法不仅给出“是否异常”，还给出“哪些粒球支撑了结论，以及这些粒球如何在图上相互关联”。

B2.10 v2 的方法学定位 GBR-AD v2 的核心创新不在于“粒球后面加一个普通 GNN”，而在于：

1. 用多尺度粒球取代单尺度像素或固定 patch 作为主表示单元。
2. 用异构粒球图显式编码结构关系，而不是只依赖卷积感受野隐式建模。
3. 用双分数机制将全局 detection 与局部 localization 解耦并重新耦合。
4. 用边界感知反投影把粒球级异常证据稳定地恢复到像素域。
5. 用证据子图把性能、机制与可解释性联结成统一证据链。

论文呈现 本小节对应方法章节主体。建议在正文中配套给出一张总架构图、一张多尺度粒球图构建图、一张证据子图示意图，以及一段算法伪代码。

2.2.4 B3 主对比实验（GBR-AD v2 正式主线）

实验内容 B1 以后所有正式 proposed 结果均按 **GBR-AD v2** 执行。主对比对象包含：RD4AD、GBR-AD(GRFM-v2)、GBR-AD(GRI-v2)。正式实验不再混用 v1 与 v2 结果。

阶段划分

1. **B3.1 RESC 方法验证阶段**: 仅在 RESC 上比较 RD4AD、GRFM-v2 与 GRI-v2, 目的是快速验证 v2 是否同时改善 image-level 与 pixel-level。
2. **B3.2 像素级三数据集阶段**: 先完成 RESC、BraTS、Liver 的三方法对比, 主攻定位能力与 PRO。
3. **B3.3 六数据集正式阶段**: 在像素级阶段结论稳定后, 再扩展到 OCT2017、RSNA、Camelyon16, 形成最终六数据集主表。
4. **B3.4 最终冻结阶段**: 锁定最终配置后, 不再改动训练策略、后处理与评测脚本, 统一生成正文主表与附录表。

统一训练设置建议

- 训练只用正常样本。
- 统一使用 3 个随机种子, 推荐 {0, 1, 42}。
- 统一采用 plateau early stop, max_epochs 设为 100, 上限固定。
- segmentation 任务以 Pixel-level AUROC 作为 early stop 监控量, image-level 任务以 Image-level AUROC 作为监控量。
- 统一优化器、学习率与权重衰减, 不允许在 baseline 与 proposed 之间使用不同 stopping policy、不同测试脚本或不同阈值策略。

主表指标

- 像素级数据集: Image-level AUROC、Pixel-level AUROC、PRO。
- 图像级数据集: Image-level AUROC。
- 所有 GBR-AD 额外报告: 平均粒球数、平均边数、推理耗时、显存峰值。

补充指标建议 为提升论文层次, v2 附录建议补充以下指标, 但不替代主表口径。

- Image-level AP。
- Image-level F1-max。
- Pixel-level AP。
- Pixel-level F1-max。
- AU-PRO0.05 或低误报预算下的 PRO 变体。
- Dice 与 mIoU, 仅限阈值选择严格基于验证集时使用。

实验目的 形成 **GBR-AD v2** 的正式主结论, 并回答以下核心问题:

1. 与 RD4AD 相比, 粒球机制是否在至少部分 BMAD 数据集上取得更高检测或定位指标。
2. 在 **GRFM** 与 **GRI** 两条输入路径中, 哪一条更适合作为主配置。
3. 粒球带来的图结构与多粒度优势, 是否值得其额外计算代价。

论文呈现 正文包含六数据集主表、Proposed 主实验表与效率表。附录补充完整 3-seed 表格、补充指标与逐数据集分析。

2.2.5 B4 受控识别实验（困难子集专测，v2 强化版）

实验内容 在像素级三数据集上构造四类困难子集。

1. **小病灶子集**：按 GT mask 面积占比排序，取最小一档。
2. **低对比子集**：按病灶与邻域背景的标准化对比度排序，取最低一档。
3. **细边界子集**：按 boundary complexity 或 perimeter-to-area ratio 排序，取最高一档。
4. **低误报预算子集**：固定较低像素误报预算后比较 lesion recall、PRO 或 fixed-FPR TPR。

实施方法

- 子集划分只使用 GT 与输入统计，不改动训练数据与训练流程。
- 全量结果与困难子集结果共用同一模型输出，保证比较公平。
- 对每个子集同时报告主指标与固定误报预算下的召回或 PRO 变体。

实验目的 直接验证 H4，即粒球机制是否对边界细节、小病灶与低对比区域具有更强表达力。使“为什么 v2 有效”可以从困难场景而非平均场景中被识别出来。

论文呈现 正文至少放 1 张困难子集对比表或 1 张多曲线图。附录给出划分阈值与子集统计量。

2.2.6 B5 证据链可解释性（正向证据与失败模式并列）

实验内容 对 RESC、BraTS、Liver 的代表样本，输出以下两类内容。

1. **正向证据链**：输入图像、粒球划分叠加、证据子图、证据热图、预测掩膜五联图。
2. **失败模式分类**：误检与漏检案例，按机制原因分类，例如大粒球稀释、小病灶未被细化、边界过平滑、图传播过度平滑、反投影权重失衡等。

实施方法

- 用节点分数与关系注意力选取 Top-K 节点构建证据子图。
- 统计证据子图覆盖 GT 的比例、证据子图平均节点数与边数。
- 对失败案例给出机制标签，而不是只给图像示意。

实验目的 强化“可审查证据”而非“只有分数”的方法学风格。让方法的性能、机制与可解释性形成闭环。

论文呈现 正文放 1 张综合大图。附录放更多案例和失败模式图库。

2.3 C 必做实验 证明贡献来自核心模块

2.3.1 C1 关键消融实验（v2 版，至少 6 组）

实验内容 在 RESC 与 BraTS 上优先完成以下消融。

1. 去掉多尺度粒球，只保留单尺度粒球。
2. 去掉异构多关系边，只保留 overlap 边。
3. 去掉原型距离分支，只保留重建误差。
4. 去掉边界感知反投影，只保留简单平均反投影。
5. 去掉轻量细化头，只保留粒球原始反投影。
6. 去掉证据子图质量项，只保留 top-k 节点平均读出。

实施方法

- 每次只改一个因素，其余训练设置保持一致。
- 每组消融运行 3 个随机种子并报告 mean 与 std。
- 主消融优先在 RESC 与 BraTS 上完成，后续再补 Liver。

实验目的 证明 v2 的提升来自粒球与图结构本身，而不是训练技巧、阈值碰巧或 backbone 偶然更强。

论文呈现 消融主表放正文。更多补充消融放附录。

2.3.2 C2 超参敏感性（聚焦 v2 核心超参）

实验内容 仅改变 1 到 2 个关键超参，输出性能曲线或小表。优先覆盖：

- 粒球纯度阈值 τ_p 。
- 粒球方差阈值 τ_v 。
- 节点数上限 N_{max} 。
- 小粒球反投影权重系数。

实验目的 展示方法对关键粒球超参不脆弱，并给出默认建议范围。

论文呈现 放入附录一页。正文用一两句话概述并引用附录图表。

2.4 D 强烈建议实验 医学场景加分项

2.4.1 D1 数据效率

实验内容 在 RESC、BraTS、Liver 上做训练数据比例实验。训练集只使用正常样本，分别取 10%、25%、50%、100%。其余设置不变。

实验目的 突出粒球先验在低数据条件下的稳定性与泛化优势。

论文呈现 给出一张曲线图或小表，放正文补充实验或附录。

2.4.2 D2 鲁棒性测试

实验内容 对测试集施加轻度扰动，不修改标注。扰动包括噪声、模糊、亮度变化、对比度变化、小角度旋转与轻微缩放。

实验目的 验证方法在噪声、设备差异和轻度域偏移下的稳定性。

论文呈现 给出一张鲁棒性曲线图或小表。

2.4.3 D3 跨分辨率与跨设备稳健性

实验内容 保持训练配置尽量不变，只改变输入分辨率或设备来源。至少在 1 到 2 个代表数据集上做跨分辨率或跨设备测试。

实验目的 验证粒球机制是否天然具有尺度适应性与成像条件稳健性。

论文呈现 正文一张小表或附录一张对比表。

2.5 E 必做实验 代价、可解释性与归档

2.5.1 E1 计算开销与结构统计

实验内容 报告参数量与推理耗时，至少给出每张图推理时间。同时报告显存峰值或可用 batch size 上限。对 GBR-AD v2 额外报告以下结构统计：

- 每张图平均粒球数。
- 每张图平均边数。
- 细粒球占比。
- 证据子图平均节点数。
- 证据子图平均边数。

实验目的 若方法引入粒球和图结构，需要说明其代价是否合理，并解释结构复杂度与性能变化之间的对应关系。

论文呈现 效率表可放正文或附录。正文建议用一行概述性能与效率的权衡。

2.5.2 E2 定性可视化与错误分析

实验内容 在 RESC、BraTS、Liver 每个数据集选择 8 到 12 张典型样本。展示输入图像、GT mask、预测 anomaly map、证据子图与二值化结果。同时选择 4 到 6 张失败案例，按误检与漏检分类并分析原因。

实验目的 医学异常检测强调定位可解释性。定性结果与错误分析提升可信度与可审查性。

论文呈现 定性图放正文。更多案例放附录。

2.5.3 E3 归档规范

每个 run 必须保存的内容

- checkpoints/
- metrics/

- figures/
- logs/
- env_python.txt
- env_torch.txt
- requirements_freeze.txt
- git_commit.txt
- git_status.txt
- run_command.txt

命名规范 所有正式对比 run 使用统一命名模板：

YYYYMMDD-HHMMSS__P-BMAD__T-anom__D-<dataset>__M-<model>__V-<variant>__S-<seed>__H-<host>
(23)

3 推荐推进顺序 (Revised after B0)

建议按如下顺序推进，以较小成本形成完整证据。

1. 保留 A 组与 B0 已完成结果，不再改写。
2. 将当前已经得到的 GBR-AD v1 结果统一标记为 **v1 provisional**。
3. 先在 RESC 上实现并验证 **GBR-AD v2**，包括 GRFM-v2 与 GRI-v2 两条路径。
4. 通过 RESC 的方法验证后，先完成像素级三数据集，即 RESC、BraTS、Liver 的主对比。
5. 补齐图像级三数据集，即 OCT2017、RSNA、Camelyon16，形成六数据集主表。
6. 在主表稳定后，执行 B4 的困难子集实验与 B5 的证据链可解释性实验。
7. 完成 C 组消融，优先验证多尺度粒球、异构边、双分数与边界感知反投影的贡献。
8. 补齐 D 与 E，形成鲁棒性、泛化性、效率、证据链与归档闭环。

4 论文交付物清单 (v2 正式版)

最终需要交付的图表与材料如下。

- 主结果表 1 张，覆盖六数据集与全部方法，报告 mean 与 std。
- Proposed 主实验表 1 张，至少包含 RD4AD、GBR-AD(GRFM-v2)、GBR-AD(GRI-v2)。
- 困难子集对比表或曲线 1 张，覆盖小病灶、低对比、细边界与低误报预算专测。
- 消融表 1 张，至少 6 行关键消融设置。
- 鲁棒性图或小表 1 张。
- 数据效率图或小表 1 张。
- 效率表 1 张，包含推理耗时、显存、粒球数、边数、细粒球占比与证据子图统计。

- 定性可视化图 1 到 2 张, 包含粒球划分、证据子图、证据热图与失败案例分析。
- 方法架构图 1 张, 明确显示多尺度粒球生成、异构图构建、双分数检测与边界感知反投影。
- 附录中的完整训练设置表、补充指标表、归档说明与 run-to-table 映射表。